AI CUP 2025 春季賽

桌球智慧球拍資料的精準分析競賽

報告說明文件

- 參賽隊伍需詳細說明系統的流程、演算法、工具與外部資源等，特別是創新性(如改了外部資源的哪一部分)。主辦單位會請專業學者、專家仔細審查，若發現分數有問題或方法說明不清之部分，請參賽隊伍補充說明，經發現有違規者，將取消獎項資格。
- 本競賽未禁止使用生成式AI，惟於競賽及撰寫報告過程如有使用生成式AI，請如實揭露，並說明作法。
- 請使用A4紙直式打字，中文字體使用標楷體，英文、數字與符號使用Times New Roman字體。
- 版面設定：邊界上下各2.54CM，左邊3.17CM、右邊3.0CM。
- 字體大小：題目20（粗體）、內文12，單行間距。
- 作者聯絡資料表：詳細資料請填寫於附件的「作者聯絡資料表」。
- 須依照以下大綱及內容說明撰寫。不可自訂標題、修改內容順序，或合併段落。但可搭配圖片說明。
- 有意爭取創意獎的隊伍，可參考「優良報告範本」，惟撰寫格式仍應遵照下方規定。
- 附件空白報告範本可參用。
- **報告大綱與撰寫規定（字數不得低於各段落規定下限）**

壹、環境

字數規定：200~600字。

內容規定：請說明使用的作業系統、語言、套件(函式庫)、預訓練模型、額外資料集等。如使用預訓練模型及額外資料集，請逐一列出來源。

貳、演算方法與模型架構

字數規定：400~1200字。

內容規定：說明演算法設計、模型架構與模型參數，包括可能使用的特殊處理方式。

參、創新性

字數規定：300~1200字。

內容規定：說明演算法之創新性或者修改外部資源的哪一部分。

肆、資料處理

字數規定：300~1500字。

內容規定：說明對資料的處理或擴增的方式，例如對資料可能的刪減、更正或增補。

伍、訓練方式

字數規定：400~1000字

內容規定：說明模型的訓練方法與過程。

陸、分析與結論

字數規定：400~2500字。

內容規定：分析所使用的模型及其成效，簡述未來可能改進的方向。分析必須附圖，可將幾個成功的和失敗的例子附上並說明之。

柒、程式碼(未於**2025/06/17 23:59前**繳程式碼連結者，將失去獲頒獎金/獎狀資格)

內容規定：請在此提供程式碼下載連結並請另外信件附檔，包含資料處理、訓練流程、預測等相關程式碼。程式碼應附README.md檔案交代安裝配置環境，重要模塊輸出/輸入，以讓第三方用戶可以除錯、重新訓練與重現結果。繳交前請確認連結有效且有開啟瀏覽權限，如連結失效視同未交。

捌、使用的外部資源與參考文獻

內容規定：參考文獻請以APA格式為主。

★註1：請確認上述資料與AI CUP報名系統中填寫之內容相同。自2023年起，獎狀製作將依據報名系統中填寫內容為準，有特殊狀況需修正者，請主動於報告繳交期限內來信moe.ai.ncu@gmail.com。，報告繳交截止時間後將不予修改。

★註2：繳交程式碼檔案與報告，請Email至：aicup2025@gmail.com，並同時副本至：t_brain@trendmicro.com與moe.ai.ncu@gmail.com。缺一不可。報告檔名與信件主旨請寫「競賽報告與程式碼/TEAM_？？？？/桌球智慧球拍資料的精準分析競賽」

附件

AI CUP 2025 春季賽
桌球智慧球拍資料的精準分析競賽報告

隊伍：TEAM_7875
隊員：陳至恆（隊長）
Private leaderboard：0.808234 / Rank 17

壹、環境

作業系統：

程式撰寫都在Google Colab上完成，透過瀏覽器介面操作。硬體加速器選擇「CPU（使用GPU和TPU可能會比較快，但是有使用上限）」。

程式語言：

Python 3.11

主要套件（函式庫，預設安裝都是最新版）：

- 資料處理：
  1. pandas（用於處理CSV檔案）
  2. numpy
  3. os（用於處理檔案路徑）
- 訊號處理：
  1. scipy.stats（kurtosis, skew）：用來計算資料分布的峰度（kurtosis）衡量分布尾部厚薄，偏度（skew）衡量分布不對稱程度。
  2. scipy.signal（welch, find_peaks）：welch 用來估計訊號的功率譜密度（PSD），解析頻域能量分布；find_peaks 則用於偵測訊號中局部峰值位置，找出頻譜或時域中的重要峰點。
  3. scipy.fft（rfft）：對實數訊號執行快速傅立葉轉換。
- 訓練與驗證：

  scikit-learn（train_test_split, StandardScaler, accuracy_score, confusion_matrix, classification_report）

1. accuracy_score：計算分類模型在測試集上的準確率（正確預測比率）。
2. confusion_matrix：產生混淆矩陣，統計 TP、FP、FN、TN 用於模型診斷。
3. classification_report：彙整 Precision、Recall、F1-score 等指標，提供更細部的分類效能分析。

- 機器學習：xgboost（XGBClassifier）
- 視覺化：matplotlib, seaborn（畫出混淆矩陣）, tqdm（在特徵處理時產生進度條）

其他：

未使用預訓練模型和額外資料集。模型都是從比賽單位提供的訓練資料訓練，而所有特徵是從train_data和test_data中提取而來。

貳、演算方法與模型架構

演算法設計：將train_data和test_data的個別數據，轉換為一個固定長度特徵向量(feature vector)。首先根據提供的 cut_point 資料，將連續的感測器數據分割成每下的「揮拍(swing)」。接著，針對每一次揮拍，提取其在時域、頻域的多個特徵。最後，將單一樣本內（例如train_data 裡面的 1.txt）所有揮拍的特徵進行匯總（如取平均值或標準差），形成一個代表該樣本的最終特徵向量。這個特徵向量隨後被輸入至分類模型進行訓練與預測。

模型架構：預測的核心模型為 **XGBoost (eXtreme Gradient Boosting)**，具體實現為 XGBClassifier分類器。XGBoost 是一種基於梯度提升決策樹 (Gradient Boosted Decision Trees, GBDT) 的高效能機器學習演算法。其基本架構為一種集成學習 (Ensemble Learning) 模型。我也有使用過其他模型，例如catboost，但是效果似乎沒有那麼突出。

download.csv 從xgboost改用catboost，並加入random search來調整參數 上傳成員 陳 至恆	2025-05-31 04:47:28	0.83922228	0.7994337098916582

模型參數：為了在準確性與防止過擬合之間取得平衡，調整了XGBClassifier 裡以下參數：

- n_estimators=500：集成中決策樹的總數量。設定為 500 棵，允許模型進行充分的學習。

- max_depth=4：每棵決策樹的最大深度。較低的深度（如 4）有助於防止模型過於複雜而導致過擬合。
- learning_rate=0.03：學習率或稱為步長縮減 (shrinkage)。較低的學習率使得每次迭代的步長變小，讓模型學習過程更穩健，需要搭配較多的樹（n_estimators）來達到最佳效果。
- subsample=0.85：訓練每棵樹時，隨機抽樣的訓練數據比例。這有助於增加模型的多樣性，降低過擬合風險。
- colsample_bytree=0.85：建立每棵樹時，隨機抽樣的特徵比例。這同樣是為了防止模型過度依賴少數幾個特徵。
- reg_alpha=1 (L1) & reg_lambda=5 (L2)：正規化懲罰項的權重。L1 有助於特徵稀疏化，而 L2 則使權重分佈更平滑，兩者共同作用以控制模型複雜度。
- random_state=42：設定隨機種子，確保每次訓練的結果具有可重現性。
- eval_metric="mlogloss"：設定多分類對數損失作為評估指標。

參、創新性

本程式創新性主要體現在**特徵工程 (Feature Engineering)** 的深度與廣度，主要的思考為如何從充滿雜訊的原始訊號中，提煉出最能區分性別、左右手、年資、等級的關鍵特徵。有別於範例程式的34個特徵，我融合了一些物理與統計維度的觀點，加上自己對桌球的一些理解，建構了一個包含 73 個特徵。

1. **多維度特徵**：
   - **時域統計特徵**：除了基礎統計量，還有計算如峰度 (Kurtosis)、偏度 (Skewness) 等高階統計量，以描述數據分佈的形狀。
   - **頻域特徵**：透過快速傅立葉變換 (FFT) 和韋爾奇法 (Welch's method)，提取如主導頻率 (Dominant Frequency)、頻譜熵 (Spectral Entropy)、頻譜質心 (Spectral Centroid) 以及特定頻帶的能量分佈（0-5Hz, 5-15Hz, >15Hz）。這些特徵能有效捕捉揮拍動作的節奏、平滑度與爆發力特性，我覺得這些可能是區分play_years和level的關鍵特徵。
   - **運動學衍生特徵**：計算加速度的一階導數「頓動 (Jerk)」，它代表加速度的變化率，能有效反映動作的流暢性與控制能力。這可能對於區分play_years和level有很好的效果。
   - **關聯性與形態學特徵**：我們計算了不同感測器軸之間的相關係數（如 corr_axgx, corr_aygy），這能反映選手在揮拍過程中身體的協調性。此外，透過 f

ind_peaks 計算加速度峰值的數量，用於量化一次揮拍中可能存在的次要發力或不穩定動作。

2. **特別特徵設計**：

- **衝擊點分析**：我在程式中定位每次揮拍裡面，最大X軸加速度 (ax) 的時間點，並以此為中心抓到前後三筆資料，共個 7 點的時間窗 (win = lambda x: x[max(0,idx-3):min(len(x),idx+4)])，並在此時刻計算的均值特徵（如 Ax_mean7, Gx_mean7）。這是希望在精確捕捉擊球瞬間的感測器狀態，捨棄掉準備與收拍階段的雜訊。
- **能量差異**：energy_diff 特徵計算總訊號能量與主發力軸（X軸加速度）能量的差異。此特徵可能反映了能量的有效利用率，能量越集中在主發力軸上，可能代表動作效率越高。

比較：在未新增更多高階特徵之前，效果沒有很好。

第七次預測.csv 修改了xgboost的參數，特徵42個 上傳成員 陳 至恆	2025-05-27 09:50:32	0.82025138	0.7663766765251239	Scoring success.

肆、資料處理

1. **載入train_info 和 test_info**：

- 使用 pandas 讀取 train_info.csv 和 test_info.csv 檔案。
- parse_cut_points 函式是用來處理cut_point，將其處理為 NumPy 的陣列。
- 對於感測器數據，透過 numpy.loadtxt 函式讀取對應 unique_id 的 txt 檔案，一樣將其處理為 NumPy 陣列。

2. **資料分割 (Data Segmentation)**：

- 原始的感測器數據是一個連續時間的揮拍動作，利用 cut_point 陣列進行資料分割，分出每一個揮拍swing。
- cut_swings 函式會遍歷 cut_point 陣列，將相鄰的切割點（cp[i] 和 cp[i+1]）之間的數據提取出來，形成一次「揮拍(swing)」。一個txt檔案會被處理成一個含多次揮拍(swings)的列表(list)（可能沒有揮滿27下）。

3. **特徵提取 (Feature Extraction)**：

函式extract_features 可以從分割出的多次揮拍列表中，提取出一個 73 個特徵的向量。這些特徵可以依其物理與訊號處理的維度，被歸類為以下三大類：

- **時域統計特徵 (Time-Domain Features)**： 這些特徵直接從原始連續時間訊號計算而來，描述揮拍動作的整體幅度、變異性、分佈形狀以及持續時間。
    - **基本統計量**：包括各軸的均值(mean)、標準差(std)、全距(range)，以及加速度和角速度的向量幅度(magnitude)的均值。
    - **高階統計量**：計算整體訊號的偏度(skew)與峰度(kurtosis)，用來描述數據分佈的不對稱性與峰值突出程度。
    - **衝擊點特徵**：以X軸加速度最大值的時間點為中心取前後三點，共7點的時間窗口，並計算均值。這個方法是在精確捕捉擊球瞬間的狀態，而非整個揮拍過程的平均。
    - **能量與時長**：計算訊號的總能量(energy)，以及每次揮拍的平均長度(avg_swing_length)與時長標準差(swing_dur_std)，反映了動作的強度與節奏一致性。
- **頻域特徵 (Frequency-Domain Features)**： 此類特徵是透過傅立葉變換將訊號從時域轉換到頻域後提取的，主要用來分析揮拍動作的節奏、平滑度與爆發力特性。
    - **頻譜能量分佈**：用韋爾奇法(Welch's method)計算功率譜密度(PSD)，並將其能量劃分為三個頻帶：低頻 (0-5Hz)、中頻 (5-15Hz) 與高頻 (>15Hz)。這三者分別可能對應動作的穩定性、主要揮拍節奏與瞬間的爆發力。
    - **頻譜形狀描述**：計算頻譜熵(spectral_entropy)來衡量訊號的複雜度，以及頻譜質心(spectral_centroid)來描述頻譜能量的中心位置。
    - **主導頻率與諧波**：用快速傅立葉變換(FFT)找到訊號中能量最強的主導頻率(dominant_frequency)及其次大峰值(second_peak)來捕捉動作的主要頻率與次要的諧波成分。
- **運動學衍生與關聯性特徵**： 此類特徵是基於原始數據進行微分、組合或關聯性分析得來，旨在量化更深層次的動作動力學與協調性。
    - **頓動 (Jerk) 分析**：計算加速度的一階導數，即「頓動」，並提取其均值與標準差。頓動的大小反映了力量變化的平滑程度，是衡量動作控制能力的重要指標。
    - **幅度分佈特徵**：計算加速度向量幅度的25、50、75百分位數。相較於最大值，百分位數能更穩健地描述選手的發力水平，不易受極端雜訊影響。

- **軸間協調性**：計算了不同感測器軸之間的「皮爾SON相關係數」，例如加速度x軸與陀螺儀x軸的相關性(corr_axgx)，或加速度x軸與y軸的相關性(corr_axay)。這些特徵量化了不同方向上肢體運動的同步與協調程度。
- **動作事件分析**：利用 find_peaks 函式計算X軸加速度訊號的波峰數量，可用於識別一次揮拍中是否包含多次發力或不流暢的停頓。

4. **後處理與輸出**：

- 對於沒有有效揮拍數據的樣本（例如 cut_point 為空或解析失敗），程式會返回一個全零的特徵向量，確保了數據處理的穩健性。
- 所有樣本的 73 維特徵被匯總後，與其基本資訊（如 unique_id, player_id 等）合併成一個最終的 pandas.DataFrame。
- 最後，這個結構化的特徵矩陣被儲存為 train_with_features_73.csv 和 test_with_features_73.csv，作為後續模型訓練的輸入。整個流程實現了從原始數據到機器學習可用數據的完整轉換。

伍、訓練方式

整個訓練過程主要分為資料準備、模型內部驗證、最終模型訓練以及預測輸出四個階段。

1. **資料準備與標準化**：使用 train_with_features_73.csv 作為訓練數據集。先將資料中的特徵與預測目標如 gender, hold_hand, play_years, level分離。再來是**特徵標準化**，使用 sklearn.preprocessing.StandardScaler 對所有特徵進行處理。
2. **模型內部驗證與調參**：

- **數據分割**：使用 sklearn.model_selection.train_test_split 函式，將訓練數據集按照 80:20 的比例分割為訓練集（X_train）與測試集（X_test），random_state設定為42 。
- **模型訓練**：使用 80% 的數據（X_train_scaled 和 y_train）來訓練 XGBClassifier 模型。超參數：

```
n_estimators=500,
max_depth=4,
learning_rate=0.03,
subsample=0.85,
colsample_bytree=0.85,
reg_alpha=1,
reg_lambda=5,
random_state=42,
```

```
eval_metric="mlogloss",
use_label_encoder=False
```

- **性能評估**：訓練完成後，模型在剩餘的 20% 數據（X_test_scaled）上進行預測。將預測結果與真實標籤 y_test 進行比較，計算出準確率 (accuracy_score)、分類報告（包含精確率、召回率、F1-score）以及畫出混淆矩陣。

3. **最終模型訓練**： 在完成內部驗證並確認模型配置的有效性後，我使用了**全部的訓練數據**（即 100% 的 train_with_features_73.csv）來訓練模型。我想說這樣可以讓模型學習到盡可能多的數據模式與變異，最大化其預測能力。訓練過程與參數設定與驗證階段完全相同。
4. **預測輸出**： 最終模型訓練完成之後，讀取 test_with_features_73.csv 檔案，並使用先前在完整訓練集上學習到的 StandardScaler 對其進行標準化。接著，使用訓練好的最終模型對標準化後的測試集特徵進行預測。預測機率的程式是使用 model.predict_proba() 。此方法會返回每個樣本屬於各個類別的機率。最後，我們將這些機率值與 unique_id 整理成一個 pandas.DataFrame，並輸出為 final_prediction_73_features.csv，作為最終的提交結果。

陸、分析與結論

模型成效分析： 針對四個目標變數（gender、hold_hand、play_years、level）分別進行驗證階段分析。

- **gender (性別) 預測**：準確率高達 **97.95%**。從圖一的分類報告中可以看出，模型對男性(male)的預測極為精準（precision=0.98, recall=1.00），但對女性(female)的召回率略低（recall=0.85），這意味著有少數女性樣本被錯誤地預測為男性。這可能源於訓練數據中性別比例不均，導致模型對多數類別（男性）的學習更為充分。

```
✅ 預測準確率：0.9795

📊 分類報告：
              precision    recall  f1-score   support

        male       0.98      1.00      0.99       336
      female       1.00      0.85      0.92        55

    accuracy                           0.98       391
   macro avg       0.99      0.93      0.95       391
weighted avg       0.98      0.98      0.98       391
```

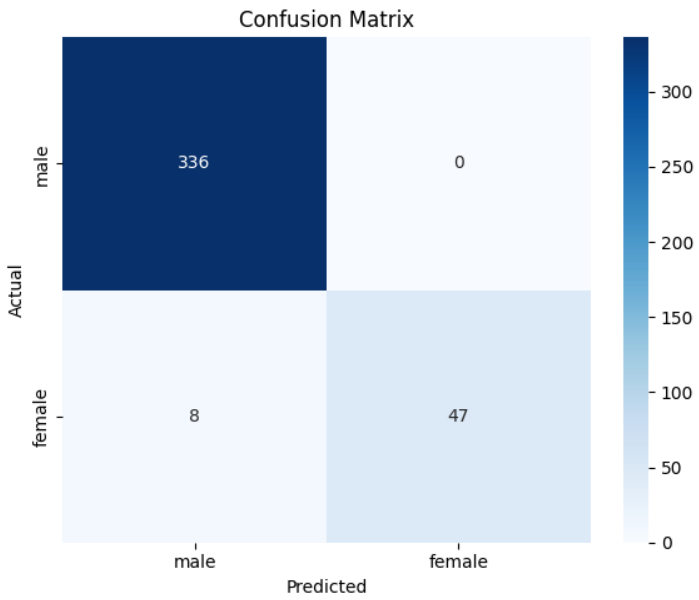

- **hold_hand (持拍手) 預測： 100%** 準確率。其實這很直覺，因為左右手在揮拍時，y軸的旋轉方向相反。就可以發現Gy_max_at_Axmax（最大X軸加速度時的Y軸角速度）與 Gy_mean7 這兩個特徵的重要性遠超其他所有特徵（只列出前十個）。
- ✅ hold_hand 預測準確率：1.0000
  📊 分類報告：

	precision	recall	f1-score	support
right-handed	1.00	1.00	1.00	318
left-handed	1.00	1.00	1.00	73
accuracy			1.00	391
macro avg	1.00	1.00	1.00	391
weighted avg	1.00	1.00	1.00	391

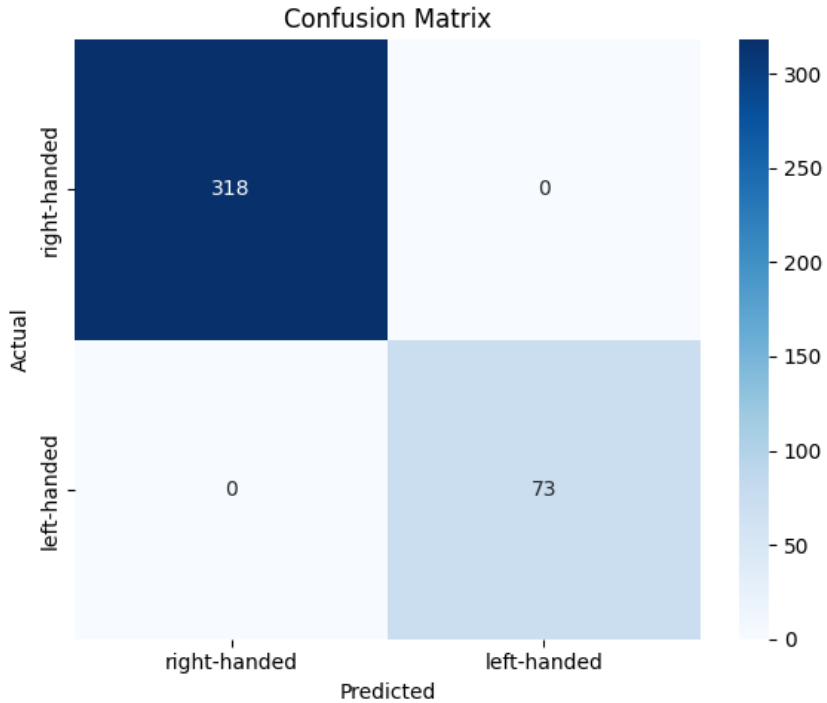

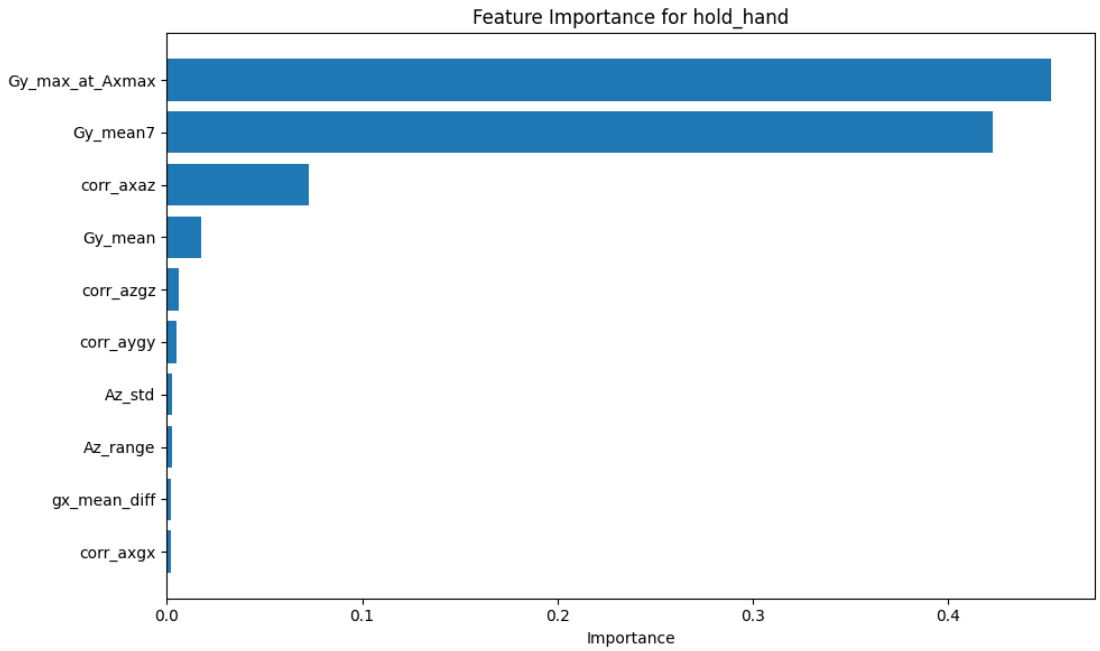

- **play_years (年資)預測**：預測準確率 **95.91%**。

```
✅ play_years 預測準確率：0.9591
📊 分類報告：
                  precision    recall  f1-score   support

play_years: 0        0.99      0.94      0.97        88
play_years: 1        0.94      0.97      0.96       168
play_years: 2        0.96      0.96      0.96       135

     accuracy                           0.96       391
    macro avg        0.96      0.96      0.96       391
 weighted avg        0.96      0.96      0.96       391
```

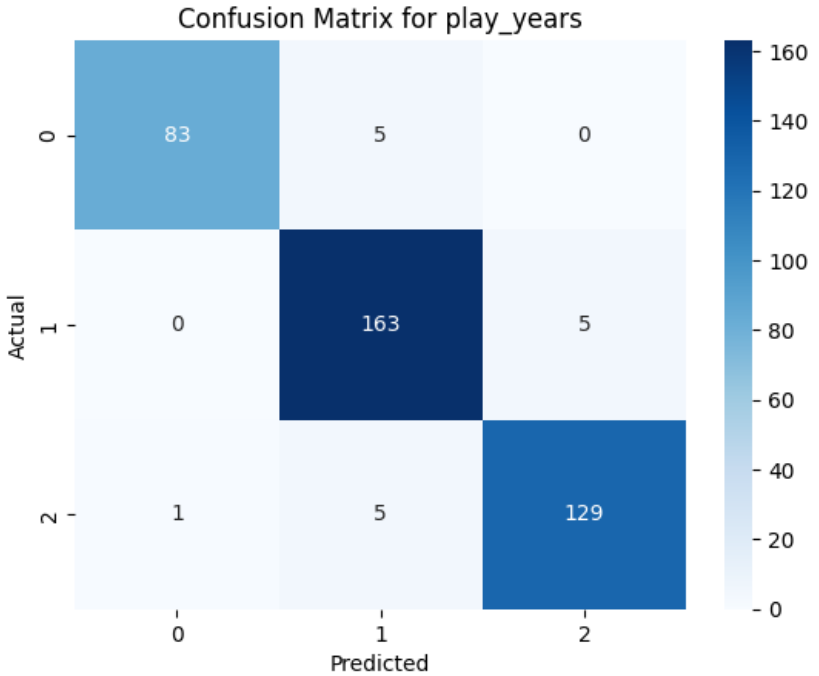

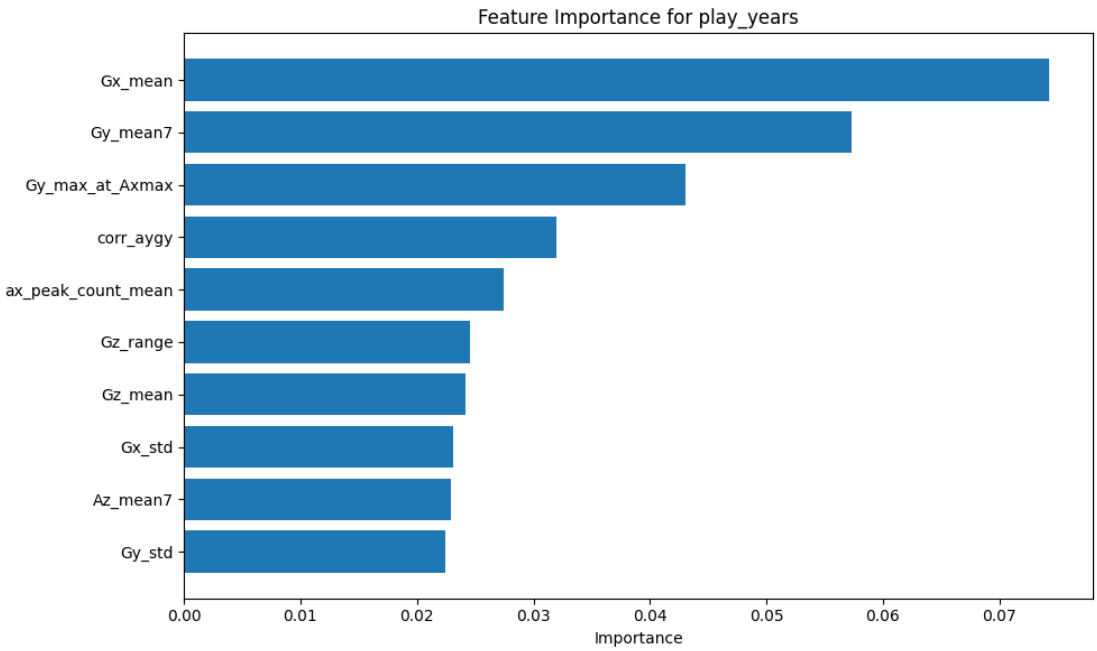

- **與 level (等級) 預測：** 預測準確率 **97.19%**。

```
✅ level 預測準確率：0.9719

📋 各等級 precision / recall / f1-score：
              precision    recall  f1-score   support

     Level 2       0.97      0.98      0.98       129
     Level 3       0.98      0.94      0.96        47
     Level 4       1.00      0.89      0.94        28
     Level 5       0.97      0.98      0.98       187

    accuracy                           0.97       391
   macro avg       0.98      0.95      0.96       391
weighted avg       0.97      0.97      0.97       391
```

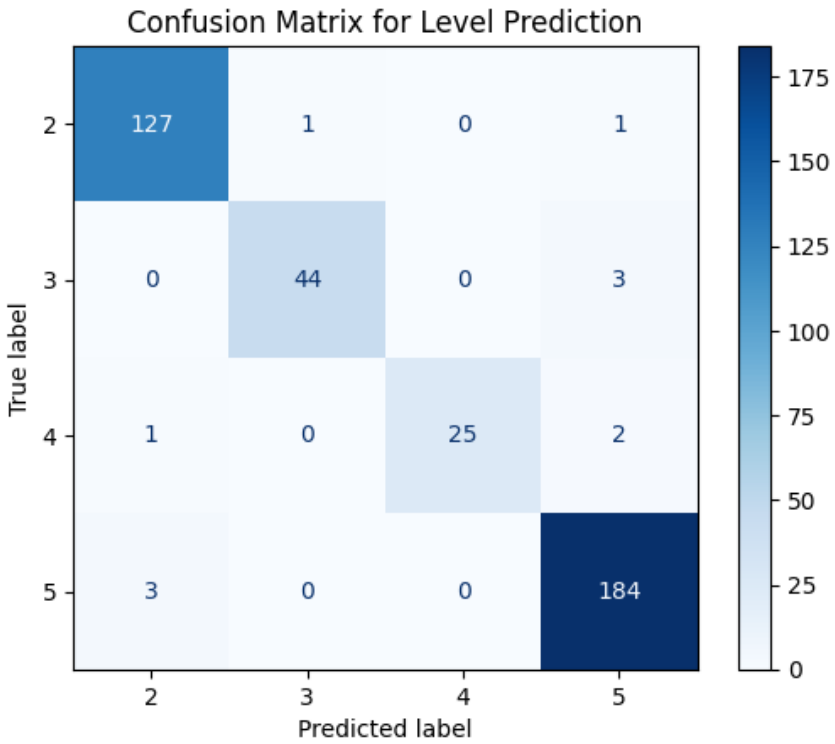

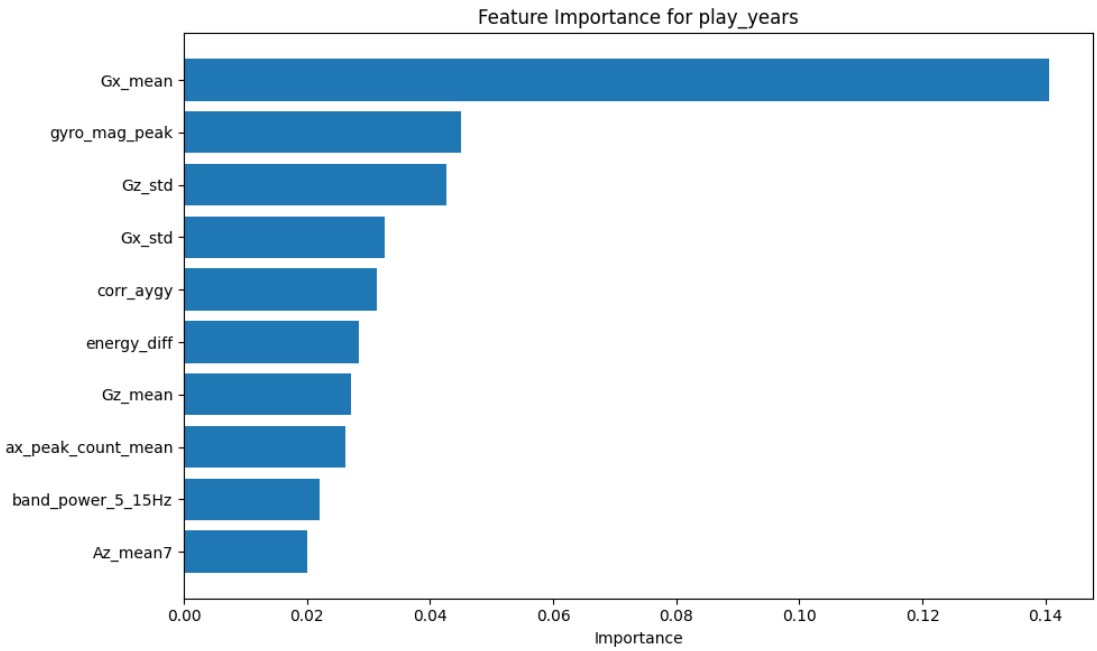

- **public_score v.s. private score分析**：
  雖然在驗證階段顯示的可行性非常高，但private score表現下降了一些，可能是因為以下原因：
  1. Overfitting to the Public Leaderboard，在程式迭代的過程過於擬合training_data。
  2. Public Test Set和Private Test Set的資料分佈很不一樣。

final_prediction_73_features.csv 使用xgboost模型，特徵增加到73個 上傳成員 陳 至恆	2025-05-29 05:21:38	0.84056077	0.8082344600701863

另外，我其實也嘗試過很多種方法，例如說增加更多的特徵（最多加到121）個、更改模型(catboost)、自動調整超參數（random search、optuna），但這些都只有在public提升，private沒有提升。

- **結論與未來展望**：透過精細的特徵工程，將原始感測器數據轉換為時域、頻域、運動學等多維度資訊的特徵，再結合 XGBoost 分類器，能夠以還可以接受的準確度提通預測。

對於未來的改進，以下有幾個方向：

1. **處理類別不平衡**：針對一些樣本數不均的問題，例如性別預測中女性樣本較少，可以嘗試使用 SMOTE (Synthetic Minority Over-sampling Technique) 等數據增強方法來生成人工的少數類樣本，以平衡數據分佈，提升模型對女性的召回率。

2. **深度學習模型**：雖然目前的方法可行度還可以接受，但也可以探索使用深度學習模型，如長短期記憶網路 (LSTM) 或一維卷積神經網路 (1D-CNN)，直接在分割出的揮拍時序數據上進行端到端的學習。這類模型能自動提取特徵，可能發現一些我們手動設計未能捕捉到的隱藏模式。

3. **模型融合 (Ensemble)**：可以嘗試訓練多個不同的模型（如 LightGBM, CatBoost, 或是簡單的邏輯回歸），然後將它們的預測結果進行加權平均或投票，以構建一個更穩健、泛化能力更強的集成模型。這個方法似乎最可行，因為我在discussion的地方有看到private第一個組別留言，他們的著重的方向就是朝模型更穩健、泛化能力更強的方向。

柒、程式碼

Google Drive連結：https://drive.google.com/drive/folders/1bnnHaOtIoRysLTOvtJ9z7hm2H4Gz6vQU?usp=sharing

（請先讀README.txt）

捌、使用的外部資源與參考文獻

- The xgboost contributors. (2022).*XGBoost Documentation*. XBoost Documentation - Xgboost 3.0.2 Documentation. https://www.google.com/url?sa=t&source=web&rct=j&opi=89978449&url=https://xgboost.readthedocs.io/&ved=2ahUKEwjtu4eq9_WNAxXYkq8BHdqoOaAQFnoECBYQAQ&usg=AOvVaw1Rb2paRgUY_gHcA0BusqY4
- Yulandy chiu的ai觀測站. (2025, October 1). [10分鐘搞懂機器學習] 8.10 XGBoost 極限梯度提升 Regression 數據處理競賽的常勝軍. Youtube. https://youtu.be/myMsYAecrFo?si=sdv9iVF5FfyskCU2
- OpenAI. (2025). ChatGPT (June 17 version; GPT-4o-mini-high) [Large language model].https://chatgpt.com/share/68514a86-84ec-800e-a319-932634cf28c1 (我有使用ChatGPT來輔助我撰寫，主要用vibe coding的方式。我列出來連結是我在寫early stopping時跟它的對話。)

作者聯絡資料表

隊伍名稱	TEAM_7875	Private Leaderboard 成績	0.8082344600701863	Private Leaderboard 名次	17
身分 (隊長/隊員)	姓名	學校+系所 中文全稱	學校+系所英文 中文全稱	電話	E-mail
隊長	陳至恆 Zhi - Heng, Chen	國立中央大學資訊電機學院不分系學士班	National Central University Interdisciplinary Program of Electrical Engineering & Computer Science	0905152632	a23144408@gmail.com

★註1：請確認上述資料與AI CUP報名系統中填寫之內容相同。自2023年起，獎狀製作將依據報名系統中填寫內容為準，有特殊狀況需修正者，請主動於報告繳交期限內來信moe.ai.ncu@gmail.com。報告繳交截止時間後將不予修改。

★註2：繳交程式碼檔案與報告，請Email至：aicup2025@gmail.com，並同時副本至：t_brain@trendmicro.com與moe.ai.ncu@gmail.com。缺一不可。